

Лабораторная работа №2

Выполнил: Кузнецов Павел М3207

Задача 2. Методом моментов найти оценку квадрата масштабирующего параметра θ распределения Лапласа (сдвиг считать нулевым). Найти смещение оценки, дисперсию, среднеквадратическую ошибку. Эксперимент для $\theta = 0.5$.

Решение:

Распределение Лапласа (θ, β) имеет функцию плотности:

$$f(x|\theta, \beta) = \frac{1}{2\theta} \exp\left(-\frac{|x - \beta|}{\theta}\right)$$

, где $\beta = 0$ (сдвиг, по условию).

Воспользуемся методом моментов, приравнявая теоретические характеристики распределения к эмпирическим хар-кам выборки:

$$\begin{aligned}\nu_1 &= E(X) \approx \bar{X}_n \text{ (при больших } n) \\ \hat{E}(X) &= \bar{X}_n \text{ (оценка мат. ожидания методом} \\ &\quad \text{моментов)}\end{aligned}$$

При этом первый момент для нашего распределения Лапласа равен нулю, так как параметр сдвига равен нулю: $E(X) = \beta = 0$

Найдём оценку квадрата параметра через второй момент:

$$\begin{aligned}\nu_2 &= E(X^2) \\ E(X^2) &= D(X) + E^2(X), E(X) = 0 \\ E(X^2) &= D(X) \\ \hat{E}(X^2) &= S_n^2 \text{ (оценка равна выборочной дисперсии)}\end{aligned}$$

при этом $\nu_2 = 2\theta^2$
 Следовательно, $\hat{\theta}^2 = \frac{S_n^2}{2}$

Найти смещение оценки, дисперсию и среднеквадратическую ошибку:

Смещение оценки находится из формулы:

$$\begin{aligned} bias(\hat{\theta}) &= E(\hat{\theta}^2) - \theta^2 = E\left(\frac{S_n^2}{2}\right) - \theta^2 = E\left(\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{2n}\right) - \theta^2 = \\ &= E\left(\frac{\sum_{i=1}^n (X_i)^2}{2n}\right) - \theta^2 = \frac{\sum_{i=1}^n E(X_i^2)}{2n} - \theta^2 = \frac{nE(X_i^2)}{2n} - \theta^2 \\ &= E(X_i^2) - \theta^2 = 2\theta^2 \implies bias(\hat{\theta}) = 0 \end{aligned}$$

Оценка несмещена. (тут непонятно, думал на защите спросить: выборочная дисперсия - это оценка для дисперсии, есть смещенный и несмещенный вариант, сверху расписываю по смещенному, следовательно оценка параметра θ автоматически тоже смещенная? Берём тогда несмещенную оценку и доказываем, что оценка смещенная, цепочка тождеств такая же.)

$$\begin{aligned} \text{Дисперсия: } var(\hat{\theta}^2) &= var\left(\frac{S_n^2}{2}\right) = var\left(\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{2n}\right) = \\ &= \frac{var\left(\sum_{i=1}^n (X_i - \bar{X}_n)^2\right)}{4n^2} = \frac{var\left(\sum_{i=1}^n (X_i)^2\right)}{4n^2} = \frac{var(X^2)}{4n^2} = \frac{E(X^4) - E^2(X^2)}{4n^2} \\ &= \frac{E^2(X^2) - D^2(X)}{4n^2} = \frac{4\theta^4}{4n^2} \\ E(X^4) &= \nu_4 = \frac{1}{2} \sum_{k=0}^4 \left(\frac{4!}{(4-k)!} \theta^k 0^{4-k} (1 + (-1)^k)\right) = 24\theta^4 \\ var(\hat{\theta}^2) &= \frac{E(X^4) - E^2(X^2)}{4n^2} = \frac{24\theta^4 - 4\theta^4}{4n^2} = \frac{5\theta^4}{n^2} \end{aligned}$$

Среднеквадратическая ошибка:

$$MSE(\hat{\theta}^2) = var(\hat{\theta}^2) = \frac{5\theta^4}{n^2}, (bias(\theta^2) = 0)$$

Проведём эксперимент для $\theta = 0.5$:

```
1 import numpy
2 import matplotlib.pyplot as plt
3 sizes = [100, 500, 1000, 10000, 100000, 1000000]
4 for i in sizes:
5     sample_array = numpy.random.laplace(0, 0.5, i)
6     # we can generate several samples of each size for better
7     # demonstration,
8     # but that is enough
9     sample_mean = numpy.mean(sample_array)
10    sample_var = numpy.var(sample_array)
11    print("mean: ", sample_mean, "var: ", sample_var, "with
12    size: ", i)
```

Вывод:

mean: -0.00758196491827923 var: 0.35240663019179036
with size: 100
mean: -0.03537322587695742 var: 0.5813357854759184
with size: 500
mean: -0.03535078067779483 var: 0.5068039470484109
with size: 1000
mean: -0.0015312248937861322 var: 0.5125913151286939
with size: 10000
mean: 0.001784203927182552 var: 0.5045930291531003
with size: 100000
mean: -0.0009742731843855747 var: 0.49967599520005107
with size: 1000000

Видим, что при увеличении n , оценка параметра θ^2 (выборочная дисперсия выборки) стремится к 0.5 (теоритическому значению)

Задача 3. Методом максимального правдоподобия найти оценку параметра θ биномиального распределения $Bin(n, \theta)$, считая n известным. Найти смещение оценки, дисперсию, среднеквадратическую ошибку. Является ли найденная оценка эффективной? Эксперимент при $n = 4, \theta = 1/5$.

Решение:

Биномиальное распределение $Bin(n, \theta)$ имеет функцию плотности:

$$f(x|n, \theta) = P(X = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

Функция правдоподобия для X :

$$L(x_1, x_2, \dots, x_n, \theta) = \prod_{i=1}^N f(x_i, \theta)$$

Оценим параметр θ методом максимального правдоподобия:

Оценка вычисляется из уравнения максимального правдоподобия, выходящего из равенства:

$$L(X_l, \theta) = (\max) \prod_{i=1}^N \binom{n}{x_i} \theta^{x_i} (1 - \theta)^{n-x_i}$$

Само уравнение:

$$\frac{\partial}{\partial \theta} \sum_{l=1}^N \ln f(X_l, \theta) = 0$$

$$\sum_{i=1}^N \ln \left(\binom{n}{x_i} \theta^{x_i} (1 - \theta)^{n-x_i} \right) =$$

$$\sum_{i=1}^N \ln \binom{n}{x_i} + \ln \theta \sum_{i=1}^N x_i + nN \ln(1 - \theta) - \ln(1 - \theta) \sum_{i=1}^N x_i$$

(логарифм произведения равен сумме логарифмов)

$$\frac{\partial}{\partial \theta} \sum_{l=1}^N \ln f(X_l, \theta) = \frac{\sum_{i=1}^N x_i}{\theta} - \frac{nN}{1 - \theta} + \frac{\sum_{n=1}^N x_i}{1 - \theta}$$

Приравняем к нулю, так как производная равна нулю в максимальной точке:

$$\frac{\sum_{i=1}^N x_i}{\hat{\theta}} - \frac{nN}{1 - \hat{\theta}} + \frac{\sum_{n=1}^N x_i}{1 - \hat{\theta}} = 0$$

Домножаем на знаменатели:

$$(1 - \hat{\theta}) \sum_{i=1}^N x_i - nN\hat{\theta} + \hat{\theta} \sum_{i=1}^N (n - x_i) = 0$$

$$\hat{\theta} = \frac{\sum_{i=1}^N x_i}{nN}$$

Смещение оценки:

$$bias(\theta^2) = E(\hat{\theta}) - \theta = E\left(\frac{\sum_{i=1}^N x_i}{nN}\right) - \theta =$$

$$= \frac{\sum_{i=1}^N E(x_i)}{nN} - \theta = \frac{nN\theta}{nN} - \theta = 0$$

, $E(X) = n\theta$, оценка несмещена.

Дисперсия оценки:

$$Var(\hat{\theta}) = Var\left(\frac{\sum_{i=1}^N x_i}{nN}\right) = \frac{1}{n^2N} Var(x_i) = \frac{n\theta(1-\theta)}{n^2N} = \frac{\theta(1-\theta)}{nN}$$

Среднеквадратическая ошибка:

$$MSE(\hat{\theta}) = var(\hat{\theta}) = \frac{\theta(1-\theta)}{nN}, (bias(\theta) = 0)$$

Проверим эффективность оценки: оценка несмещена, проверим выполняется ли рав-во Рао-Крамера (выходящее из нер-ва). Информация Фишера:

$$\begin{aligned} I(\theta) &= E\left(\frac{\partial \ln(P(X=x_i))}{\partial \theta}\right)^2 = \\ &E\left(\frac{\partial (\ln \binom{n}{x_i} + x_i \ln(\theta) + (n-x_i) \ln(1-\theta))}{\partial \theta}\right)^2 = E\left(\frac{x_i}{\theta} - \frac{n-x_i}{1-\theta}\right)^2 = \\ &E\left(\frac{x_i - n\theta}{\theta(1-\theta)}\right)^2 = \frac{E(x_i - n\theta)^2}{\theta^2(1-\theta)^2} = \frac{Var(x_i)}{\theta^2((1-\theta)^2)} = \frac{n\theta(1-\theta)}{\theta^2((1-\theta)^2)} = \frac{n}{\theta(1-\theta)} \\ &\frac{1}{I(\theta)} = var(\hat{\theta}) \implies \end{aligned}$$

\implies оценка эффективна.

Проведём эксперимент для $n = 4, \theta = \frac{1}{5}$:

```
1 sizes = [100, 500, 1000, 10000, 100000, 1000000]
2 for i in sizes:
3     sample_array = numpy.random.binomial(4, 0.2, size = (100, i
4     ))
5     sample_mean = numpy.mean(sample_array, axis=1)
6     sample_theta_estimation = sample_mean/4
7     sample_theta_estimation = numpy.mean(
8     sample_theta_estimation)
9     print ("mean of theta estimation for samples of size", i, "
10    = ", sample_theta_estimation)
```

Вывод:

Среднее оценки параметра (эмпирических значений)
для выборок размера 100 : – 0.198725

Среднее оценки параметра (эмпирических значений)
для выборок размера 500 : – 0.19977

Среднее оценки параметра(эмпирических значений)
для выборок размера 1000 : -0.20036

Среднее оценки параметра(эмпирических значений)
для выборок размера 10000 : -0.200046000000000003

Среднее оценки параметра(эмпирических значений)
для выборок размера 100000 : -0.20001625

Среднее оценки параметра(эмпирических значений)
для выборок размера 1000000 : -0.2000397675

Видим, что при увеличении n , оценка параметра θ
(выборочная дисперсия выборки) стремится к 0.2 (тео-
ретическому значению), следовательно является эффек-
тивной